

大模型Token中转站-方案_副本

大模型 Token 中转站 — 产品解决方案（PRD）

1. 方案概述

本方案将平台定位为 **大模型厂商的分销中转站**：向上以渠道商身份对接 Kimi、MiniMax、DeepSeek、通义、文心、豆包等原厂，统一聚合其模型能力；向下以统一 **OpenAI 兼容 API** 分销给企业与开发者，并按 Token 计量计费，赚取分销差价。

方案核心为 **三级账号体系**（平台运营 → 企业客户 → 企业员工），并对照市场主流中转方案（OneAPI/New API/硅基流动）补齐 **令牌增强、分组倍率、兑换码、渠道加权与故障自愈、缓存计费、模型路由、限流安全、日志审计、告警通知、开发者中心** 等标准能力，达到生产级中转站要求。

2. 产品说明

2.1. 产品定位（分销商 / 中转站）

- 对 **上游原厂**：以渠道商身份聚合接入，统一协议、统一计量。
- 对 **下游企业/开发者**：一套 OpenAI 兼容 API Key 统一调用多厂商，无需关心底层。
- 对 **平台运营方**：分销差价（批发价 vs 零售价）+ 配额 + 套餐实现商业化闭环。

2.2. 整体架构



14		Kimi		MiniMax		DeepSeek		通义		文心		豆包	
15		+ 多接口: Chat / Embedding / Rerank / Realtime ...											
16													
17	数据层: 三级账号 / 分组 / 密钥 / 渠道 / 配额 / 账单 / 日志												

2.3. 三级账号体系（方案核心）

形成「平台运营 → 企业客户 → 企业员工」分销管控链路，逐级配额下发、逐级计量计费。

一级：系统管理员（平台运营 / 分销商运营）

能力	说明
原厂对接（Token 分销）	对接原厂，管理渠道、采购成本价、权重、故障转移
客户计量计费	按 Token 零售价对客户计费、出账、对账，核算分销毛利
账号管理	客户管理员开户、启用/禁用、信息维护
客户配额管理	为每个客户分配总配额/总余额/月度上限
价格与套餐	零售价、Markup 倍率、模型倍率、套餐/流量包
全局运营看板	全局 Token 消耗、原厂成本、客户增长、平台毛利

二级：客户管理员（企业侧管理员）


能力	说明
子账号（客户账号）管理	为本公司人员创建/启用/禁用客户账号
配额管理（拆分下发）	将总配额拆分至部门/人员/项目（分组）
计量计费	本公司总消费、各子账号消费明细与趋势
资源统计	本公司用量看板（模型/人员/时间维度）
资源申请审批	审批本公司人员的 API Key、配额提升申请

三级：客户账号（终端使用方）

能力	说明
----	----

资源申请	申请 API Key、配额/额度提升（提交客户管理员审批）
API 调用	使用分配的 Key 按 OpenAI 协议调用模型
资源使用看板	个人用量、余额/剩余配额、调用记录、消费明细
在线体验	文本对话、批量推理等

账号关系与隔离



- 系统管理员可见全部客户；客户管理员仅管本企业；客户账号仅见自身资源。

2.4. 核心功能

- 统一协议 + 多协议互转：**对外 OpenAI 兼容，并支持 Claude / Gemini 格式互转（参考 New API）。
- 多厂商聚合分发：**统一接入 Kimi / MiniMax / DeepSeek / 通义 / 文心 / 豆包。
- 三级账号与配额下发：**配额系统管理员 → 客户管理员 → 客户账号逐级拆分。
- 分组与倍率体系：**用户/令牌/模型分组 + 模型倍率、缓存倍率，灵活计价（参考 New API）。
- 智能路由与 Fallback：**按权重/价格/延迟路由，模型级与渠道级双重故障转移。
- 缓存计费：**区分缓存命中（如 prompt caching），降低重复前缀成本。
- 计量计费：**按 Token 计量，预付费余额实时扣减，分销差价盈利。
- 限流与安全：**IP 白名单、模型限制、速率限制、内容安全。
- 高并发 / 弹性伸缩：**高负载下稳定与响应。
- 日志与审计：**请求级日志、消费明细、审计留存。
- 告警通知：**渠道异常、余额/额度预警、Webhook。

2.5. 用户侧整体流程

- 系统管理员** 对接原厂渠道、配置价格/倍率/套餐、开设客户管理员并分配客户总配额。
- 客户管理员** 登录后创建客户账号，将总配额拆分下发，审批资源申请。
- 客户账号** 申请 API Key 与配额，按协议接入调用模型。

4. 每次调用经网关 **路由 → 缓存 → 计量 → 配额扣减**，看板实时更新。

5. 客户管理员按公司维度看统计；系统管理员按客户维度计费对账。

2.6. 版本规划

- **1.0 基础版**：模型广场、在线推理、密钥管理、监控统计。
 - **1.5 中转站分销增强版**：三级账号、原厂渠道、Token 计费、配额、批量推理、计算器。
 - **2.0 生产级中转站**：分组倍率、兑换码、渠道加权自愈、缓存计费、模型路由、限流安全、日志审计、告警、开发者中心。
-

3. 功能需求（按模块）

3.1. 主菜单（按角色区分）

仅面向公有云；不同角色可见菜单不同。

系统管理员：模型广场、文本对话、批量推理、API Key 管理、监控统计、配额管理、计费账单、客户管理、原厂渠道管理、价格与套餐、全局运营看板、兑换码管理、告警设置、开发者中心。

客户管理员：模型广场、文本对话、批量推理、子账号管理、配额下发、资源统计、计费账单、资源申请审批、API Key 管理。

客户账号：模型广场、文本对话、批量推理、资源申请、资源使用看板、API Key 管理。

3.2. 模型广场（参考火山「智能广场 / 模型中心」）

- **入口**：【模型服务】 - 【模型广场】
- **来源**：【原厂渠道管理】接入的 Kimi / MiniMax / DeepSeek / 通义 / 文心 / 火山seed。
- **展示**：厂商、模型名称、分类（文本/深度思考/向量/视觉/语音/Realtime）、上下文长度、是否流式、单价、热度排行。
- **功能**：【API 参考】（文档页，私有环境可隐藏，默认开）、【立即体验】（跳文本对话，默认生成 default 密钥并选定模型）。
- **上架/下架**：管理员控制广场可见性。独立保留文档页。

3.3. API Key / 令牌管理（市场增强）

- **入口**：各级账号【API Key 管理】
- **基础**：创建、更新、启用、禁用、删除；展示 API 域名与路径；密钥默认隐藏、可复制；创建仅输名称、成功弹窗展示；删除单次 1 个。
- **市场增强（参考 OneAPI/New API 令牌能力）**：
 - **过期时间**：支持设置密钥有效期，到期自动失效。

- **IP 白名单限制**：仅允许指定 IP/网段调用，提升安全。
- **模型限制**：限定该密钥可调用的模型范围。
- **额度类型**：无限额度 / 按金额 / 按次数 三种额度模式。
- **令牌分组**：密钥归入分组，组内共享倍率与配额策略。
- **状态**：启用/禁用即时生效。
- **三级补充**：Key 与账号绑定，调用按归属逐级计量；可绑定配额策略（见 3.7）。

3.4. 监控统计 / 资源统计（分级看板）

- **入口**：系统管理员【监控统计】、客户管理员【资源统计】、客户账号【资源使用看板】
- **需求**：
 - a. 左上角切换，按 **密钥 / 模型 / 厂商渠道 / 分组** 查询。
 - b. 按 Key：项目维度汇总 + 单 Key 明细。
 - c. 按模型：仅单一模型，不支持多模型汇总。
 - d. 时间：前端规范样式，最大 180 天；单图支持放大与导出。
 - e. 监控项：总 Token、输出 Token、输入 Token、命中缓存数（仅求和值）。
 - f. **分级看板**：系统管理员全局+客户下钻；客户管理员本公司+子账号下钻；客户账号个人用量/余额/调用记录。

3.5. 配额管理（三级下发 + 分组预算）

配额从系统管理员 → 客户管理员 → 客户账号逐级拆分；并以「分组」承载部门/项目预算。

- **系统管理员（客户配额）**：为每个客户分配总配额/总余额/月度上限；超额全局拦截。
- **客户管理员（部门/人员）**：将总配额拆分至部门/人员/项目（即「分组」）；设单账号 QPS、并发、单日/单月上限。
- **客户账号**：在配额内使用；超额申请提升（走审批）。
- **分组预算（参考 New API 分组）**：客户管理员可建多个分组（如「研发组」「运营组」），每组独立模型倍率与预算，便于内部成本核算。
- **维度**：调用频率（QPS/并发）、用量额度（Token/金额）、余额阈值（预警、归零停服）。
- **需求要点**：超限返回 `quota_exceeded`；管理员可临时提额；变更实时生效。

3.6. 原厂渠道管理（系统管理员 · 分销核心 · 市场增强）

- **入口**：【运营后台】 - 【原厂渠道管理】
- **对接原厂（首批）**：Kimi、MiniMax、DeepSeek、通义千问、文心一言、豆包/火山方舟；后续可扩展至 28+ 渠道（OpenAI、Azure、Claude、Gemini、智谱、阶跃等）。

- **多接口覆盖（参考 New API）：** Chat / Embedding（向量） / Rerank（重排序） / Realtime（实时语音） / 视觉 / 图片生成 等，分销商可统一分发。
- **新增渠道配置项：**

配置项	说明
渠道名称	如「MiniMax-主」
原厂类型	适配器（协议/字段映射）
API Base URL	原厂接口地址（支持代理/私有）
API Key / 多 Key	多 Key 轮询，均衡配额
支持模型	该渠道可服务模型
模型映射	原厂模型名 → 平台统一标识
权重 / 优先级	加权随机 分配 / 故障转移顺序
状态	启用 / 禁用
限速	渠道级 QPS/并发
成本价	原厂批发单价（差价核算）

- **高可用（市场增强）：**
 - 同模型多渠道 **加权随机** 分配流量。
 - 失败 **自动重试** 并降级至下一优先级渠道。
 - **故障渠道自动禁用：** 健康探测失败自动摘除，恢复后自动回归。
- **监控：** 成功率、延迟、今日 Token、原厂剩余额度、最近错误；异常告警一键禁用。
- **需求要点：** OpenAI 兼容为主，非兼容经适配器；支持流式/非流式透传；多 Key 均衡配额。

3.7. 计费与账单 — Token 计费（分销差价 · 市场增强）

- **入口：** 系统管理员【计费账单】、客户管理员【计费账单（本公司）】
- **计费模型：** 按 Token 消耗计费，区分输入/输出；单位 **元/1K Token** 或 **美元/1M Token**；按模型维度定价。
- **倍率体系（参考 New API）：**
 - **模型倍率：** 每个模型设倍率（如 deepseek 倍率 1、gpt 倍率 5），实际扣费 = 基础价 × 模型倍率 × 用量。

- **缓存倍率**：缓存命中部分按更低倍率计费。
- **分组倍率**：不同用户/令牌分组可叠加不同倍率，实现差异化定价。
- **定价与差价（系统管理员）**：配置零售价 / 模型倍率；在原厂成本价上设 Markup，形成毛利；支持套餐/流量包。
- **额度模式（参考中转站）**：无限额度 / 按金额 / 按次数 三种扣费模式。
- **余额与扣费**：预付费余额，调用完成实时扣减；不足返回 `insufficient_balance` 并停服；支持用户/密钥额度与单日/单月上限。
- **充值**：余额充值流水；**兑换码** 与 **在线支付（易支付/Stripe，参考 New API）** 见 3.20。
- **账单查询**：系统管理员按客户/模型/渠道查「客户消费 - 原厂成本 = 毛利」；客户管理员按子账号/模型/时间查本公司明细，导出（最大 180 天）。
- **需求要点**：计费与网关调用原子化（成功才扣费）；用量以网关上报为准，与监控共用日志；余额/额度阈值预警。

3.8. Token / 价格计算器（参考火山「Token 计算器」）

- **入口**：模型广场详情页 / 独立计算器
- 选模型后输入预估输入/输出 Token，实时估算费用；多模型成本对比辅助选型；展示各模型单价与倍率表。

3.9. 资源申请（客户账号）

- **入口**：【我的】 - 【资源申请】
- 申请 API Key（归属项目/用途）；申请配额/额度提升（理由+预估用量）；查看状态（待审批/通过/驳回）。
- 提交至客户管理员，在【资源申请审批】处理。

3.10. 账号管理（三级）

- **系统管理员 — 客户账号管理（开户）**：创建/启用/禁用客户管理员；维护企业信息；分配客户总配额/余额/月度上限；查看客户列表、状态与消费概览。
- **客户管理员 — 子账号管理**：创建/启用/禁用客户账号；总配额拆分下发；审批子账号资源申请；建分组做内部预算。
- **注册与登录**：系统管理员内置/后台创建；客户管理员由系统管理员开户；客户账号由客户管理员创建或邀请注册；支持密码登录、找回/重置；状态 正常/禁用/欠费停服；严格租户隔离。

3.11. 管理员界面

- 复用**管理界面**，定义功能并出具业务配置方案。

- **系统管理员模块：**客户管理、原厂渠道管理、价格与倍率、全局配额、计费配置、兑换码、告警、全局运营看板、开发者中心。
- **客户管理员模块：**子账号管理、配额下发、资源统计、计费账单、申请审批。

3.12. 模型路由与 Fallback

在渠道级负载均衡之上，增加模型级与请求级智能路由，提升可用性与性价比。

- **智能路由策略（可配置）：**按 **权重**（默认）、按 **价格最低**、按 **延迟最低**、按 **可用性最优** 选择渠道/模型。
- **模型级 Fallback：**主模型调用失败时，按预设顺序切换至 **备用模型**（如 deepseek 失败时降级 qwen），保障业务不中断。
- **渠道级重试/降级：**失败时自动重试下一渠道，结合 3.8 故障自愈。
- **需求要点：**Fallback 模型可配置；切换对用户透明；记录实际路由路径便于排查。

3.13. 限流与安全

- **IP 白名单：**渠道/密钥级允许访问的 IP/网段。
- **模型限制：**密钥可调用模型范围约束。
- **速率限制（Rate Limiting）：**按 用户 / 密钥 / IP 维度设置 QPS、并发、单分钟请求数；超限返回。
- **内容安全：**请求/响应敏感词过滤、合规审计；可选对接内容安全服务，违规请求拦截并记录。
- **需求要点：**限流策略可分级（平台默认 + 客户自定义）；安全事件留痕。

3.14. 调用日志与审计

- **请求级日志：**每笔调用记录 时间、用户/密钥、模型、厂商渠道、路由路径、输入/输出 Token、耗时、状态、费用。
- **消费明细：**按用户/密钥/模型/时间聚合，与计费账单同源。
- **审计留存：**操作审计（开户、改价、提额、禁用）+ 调用审计，满足合规追溯；日志保留周期可配置。
- **导出：**支持按条件导出 CSV，用于对账与排查。
- **需求要点：**日志量较大，按需采样/异步写入；敏感字段脱敏。

3.15. 告警与通知

- **触发场景：**原厂渠道异常/故障禁用、成功率跌破阈值、余额/额度低于阈值、单日消费超预算、限流触发。
- **通知渠道：**站内公告。
- **配置：**系统管理员设全局告警规则；客户管理员设本企业阈值。

- 需求要点：告警去重与收敛，避免风暴。

4. 三级账号体系能力对照表

能力	系统管理员（一级）	客户管理员（二级）	客户账号（三级）
原厂对接 / Token 分销	✓	—	—
客户计量计费 / 对账	✓（按客户）	✓（本公司）	查看个人
账号管理	客户管理员开户	子账号管理	自身
配额管理	客户总配额	部门/人员下发 + 分组预算	配额内使用/申请
资源统计看板	全局 + 客户下钻	本公司 + 子账号下钻	个人看板
资源申请审批	—	✓ 审批子账号	✓ 提交申请
API 调用 / 在线体验	✓	✓	✓
原厂渠道 / 价格倍率	✓	—	—
兑换码 / 在线充值	✓ 发放/接入	本企业可用	个人充值
告警 / 开发者中心	✓ 全局	本企业阈值	查看